

Projet de résolution de problèmes

Metaheuristiques pour la résolution du problème de l'arbre de Steiner de poids minimum

Alexandre Bontems, Gualtiero Mottola

TABLE DES MATIÈRES

1	Introduction	1
2	Algorithme génétique	2
2.1	Population initiale	2
2.2	Processus de sélection	3
2.3	Opérateurs de croisement et mutation	4
2.4	Performances	5
3	Recherche locale	5
4	Conclusion	5

1. INTRODUCTION

Ce projet aborde la résolution du problème de l'arbre de Steiner de poids minimum avec deux méthodes : un algorithme génétique et un algorithme de recherche locale. Le problème d'optimisation combinatoire consiste en la recherche d'un arbre de poids minimum couvrant les nœuds dits terminaux d'un graphe. La solution peut comprendre des nœuds facultatifs, dits de Steiner, pour être fortement connexe. La Figure 1 montre une solution optimale en bleu qui comprend les nœuds de Steiner u_1 et u_2 .




FIGURE 1 – Exemple de Steiner Tree Problem

L'algorithme génétique a été conçu de façon modulaire afin de pouvoir accueillir différentes fonctions d'initialisation, différents opérateurs de croisement et de mutation, etc. Il a ainsi été possible d'étudier les performances de chaque composante pour les différents types d'instances considérés. L'algorithme de recherche locale réutilise les mêmes fonctions d'initialisation.

2. ALGORITHME GÉNÉTIQUE

Un algorithme génétique consiste généralement en l'enchaînement des actions suivantes sur plusieurs générations : *Initialisation*, *Sélection*, *Crossover*, *Mutation*. La phase d'initialisation permet de générer une population d'individus qui seront ensuite sélectionnés, croisés, et mutés afin de construire la génération suivante.

2.1. POPULATION INITIALE

Les individus solutions sont représentés par un vecteur de variables binaires pour chaque sommet facultatif, prenant la valeur 1 si le sommet est présent dans la solution et 0 sinon. Par exemple, la solution de l'exemple en Figure 1 est représenté par le vecteur suivant.

u_1	u_2	u_3	u_4
1	1	0	0

INITIALISATION ALÉATOIRE Une première approche pour la phase d'initialisation a été de produire des individus en choisissant, de manière aléatoire, les sommets pris dans la solution. Les proportions de sommets pris dans une solution sont tirées aléatoirement entre 5 et 20% lors de la génération d'un individu. On essaye ainsi de se rapprocher le plus possible de l'optimum tout en s'assurant une certaine diversité dans la population de départ.

La Table 1 montre des coûts de départ pour quelques instances. On se rend vite compte qu'ils se trouvent souvent bien loin des solutions optimales et c'est pourquoi on utilisera par la suite des heuristiques de construction. Le temps de résolution étant borné à 5 minutes, on essaye ainsi d'améliorer les performances de nos algorithmes. Cette méthode de génération reste cependant intéressante pour introduire de la diversité dans nos population initiales. Elle sera désignée par **random** dans la suite de ce rapport.

Génération	Instance	Proportion	Coût	Opt
1	b02	0.31	5075	83
2	b02	0.45	3602	83
3	b02	0.35	3102	83
1	b08	0.40	5112	104
2	b08	0.47	5180	104
3	b08	0.36	3174	104
1	c18	0.46	312	113
2	c18	0.44	302	113
3	c18	0.31	238	133

TABLE 1 – Exemple de population initiale aléatoire

HEURISTIQUE DU PLUS COURT CHEMIN L'heuristique de construction du plus court chemin (**shortest_path**) reste la plus efficace en terme de coût initial. Elle consiste en la construction d'un arbre couvrant depuis le graphe des distances des sommets terminaux. Puisqu'elle est déterministe, on procède avant la génération à une randomisation du graphe problème pour obtenir davantage d'individus différents.

La Table 2 présente les coups obtenus grâce à cette heuristique pour quelques instances. Le graphe d'origine est altéré de 5 à 20% pour chaque poids mais il est apparent que la perturbation de l'heuristique est faible : les solutions générées sont souvent identiques.

Génération	Instance	Coût	Opt
1	b02	92	83
2	b02	94	83
3	b02	92	83
1	b08	113	104
2	b08	113	104
3	b08	113	104
1	c18	137	113
2	c18	142	113
3	c18	139	133

TABLE 2 – Génération avec `shortest_path`

HEURISTIQUE DE L'ARBRE COUVRANT MINIMUM Cette heuristique (`mst`) nous permet d'améliorer la diversité de la population initiale. Quelques générations sont présentées en Table 3.

Génération	Instance	Coût	Opt
1	b02	93	83
2	b02	97	83
3	b02	96	83
1	b08	111	104
2	b08	107	104
3	b08	107	104
1	c18	224	133
2	c18	210	133
3	c18	209	133

TABLE 3 – Génération avec `mst`

Notre algorithme génétique utilisera une population constituée d'individus issus de ces trois méthodes de génération. L'heuristique `shortest_path` est très coûteuse pour des graphes avec beaucoup de nœuds terminaux et/ou d'arêtes, et elle produit peu d'individus différents malgré la randomisation du graphe de départ. C'est pourquoi seul un faible pourcentage y sera dédié. Par exemple, une population initiale pourra comprendre 5% de `shortest_path`, 60% d'heuristique de `mst` et 25% de `random`.

2.2. PROCESSUS DE SÉLECTION

L'étape suivante demande la sélection de plusieurs individus parmi la population courante, à partir desquels seront produits des "enfants" pour constituer la génération suivante. L'idée est de choisir les meilleurs éléments tout en introduisant de l'aléa afin d'espérer une évolution. Plusieurs processus différents ont été implémenté et testés.

FITNESS PROPORTIONATE SELECTION (FPS) À chaque individu correspond une mesure de fitness ($\frac{1}{\text{coût}}$) qui augmente avec la qualité de la solution et qui nous permet, dans cette sélection, de choisir les individus selon leur coût. Ceux avec le coût le plus bas auront le plus de chance d'être choisis. Ainsi, l'implémentation est simple : une liste cumulative de fitness est construite, une valeur aléatoire est tirée et un simple parcours de liste permet de choisir un individu. Les performances de ce processus ainsi que des suivants sont détaillés en Section 2.4.

STOCHASTIC UNIVERSAL SAMPLING (SUS) Un autre processus, moins biaisé envers les solutions de grandes fitness, est SUS. Une seule position aléatoire est tirée et les individus sont choisis depuis cette position dans la population selon des intervalles réguliers. On s'assure ainsi que les meilleures solutions ne soient pas choisies invariablement. Le pseudo-code suivant, trouvé sur Wikipedia, a été implémenté.

```

1 F := total fitness of Population
2 N := number of offspring to keep
3 P := distance between the pointers (F/N)
4 Start := random number between 0 and P
5 Pointers := [Start + i*P | i in [0..(N-1)]]
6
7 Keep = list()
8 for P in Pointers
9     i := 0
10    while fitness sum of Population[0..i] < P
11        i++
12    add Population[i] to Keep
13 return Keep

```

TOURNAMENT SELECTION (TS) Enfin, un processus de tournoi a été implémenté : un sous-ensemble de la population est choisi et est trié (par défaut 70% de la population initiale est choisi aléatoirement). La probabilité pour un individu d'être tiré est ensuite décidée selon le pseudo-code suivant.

```

1 choose the best individual from the tournament with probability p
2 choose the second best individual with probability p*(1-p)
3 choose the third best individual with probability p*((1-p)^2)
4 and so on

```

Puisque les individus sont tirés parmi un sous-ensemble aléatoire de la population, on s'assure ici aussi de ne pas toujours choisir les meilleures solutions. Ainsi les opérateurs de croisement utilisés pourront peut-être mener vers une évolution positive de la population.

2.3. OPÉRATEURS DE CROISEMENT ET MUTATION

Les individus choisis lors de la sélection sont croisés et mutés avec les opérateurs décrit dans cette section. La nouvelle population est choisie parmi les parents et les enfants par élitisme : 30% est constituée des meilleures solutions et le reste est tiré aléatoirement parmi les restants (toujours dans une optique de diversité de la population).

CROISEMENT À POINT (SPC) L'opérateur de croisement à point unique consiste à choisir une position aléatoire dans les solutions parentes et à intervertir les différentes parties des parents autour de ce point pour produire deux enfants (illustré en Figure 2). C'est l'opérateur qui a été le




FIGURE 2 – Exemple de croisement à point unique

plus prometteur dans nos tests mais beaucoup d'opérateurs souvent utilisés dans les algorithmes génétiques sont absents de ce projet.

CROISEMENT UNIFORME (UC) Dans ce croisement, deux enfants sont produits et pour chaque bit d'un enfant, on choisit soit le bit du premier parent soit du second parent à la même position. La probabilité pour chaque bit d'appartenir à un quelconque parent est donc uniforme mais il est très facile d'imaginer une probabilité proportionnelle à la qualité du parent. Malheureusement, par manque de temps, aucune implémentation n'est proposée ici et seul un croisement uniforme a été testé.

MUTATION Un unique type de mutation a été testé : chaque bit a une probabilité de $\frac{1}{s}$ d'être modifié avec s le nombre de bits d'une solution. En moyenne on a donc un bit muté par enfant.

2.4. PERFORMANCES

Dans ce rapport, tous les algorithmes sont testés sur les ensembles d'instances disponibles à l'adresse <http://steinlib.zib.de/testset.php>. Les instances sélectionnées parmi les ensembles B , C , D et E , sont répertoriées en Table 4.

Nom	Nb de sommets	Nb d'arêtes	Sommets terminaux	Opt
b02	50	63	13	83
b08	75	94	19	104
b10	75	150	13	86
b17	100	200	25	131
b18	100	200	50	218
c02	500	625	10	144
c05	500	625	250	1579
c12	500	2500	10	46
c18	500	12500	83	113
d02	1000	1250	10	220
d04	1000	1250	250	1935
d10	1000	2000	500	2110
e02	2500	3125	10	214

TABLE 4 – Instances de tests

Les performances de l'algorithme génétique sont visibles en Table 5. Chaque exécution est alloué un maximum de 100 itérations et une population de 100 individus. Les solutions moyennes présentées résultent chacune de 4 exécutions selon les mêmes paramètres. Pour les instances *b02*, *b08*, *b10*, *b17* et *e02*, les populations initiales sont générées dans les proportions suivantes : 10% de *shortest_path*, 30% de *random* et 60% de *mst*.

3. RECHERCHE LOCALE

4. CONCLUSION

Instance	Selection	Operator	Avg Time (secs)	Avg Solution	Opt	Error
b02	FPS	SPC	7.70	83	83	0%
b08	FPS	SPC	10.38	105.5	104	1.4%
b08	SUS	SPC			104	
b10	FPS	SPC	9.37	86	86	0%
b17	FPS	SPC	17.4	131.5	131	0.3%
c02	FPS	SPC	13.35	148	144	2.7%
c05	FPS	SPC	102.9	1598	1579	1.2%
c12	FPS	SPC	16.8	57.25	46	24.4%
c18	FPS	SPC	235.6	158.25	113	40%
d02	FPS	SPC	25.82	233.5	220	6%
d04	FPS	SPC	157.6	2087.75	1935	7%
d10	FPS	SPC	257.3	2182	2110	3.4%
e02	FPS	SPC	41.2	244	214	14%

TABLE 5 – Performances de l’algorithme génétique